

第 10 章 表格和画图

上一章的数组只有数字，列是什么意思得自己记着。真实数据都有列名，还常常缺东少西。这一章用 pandas 处理带列名的表格，再把结果画成图。

装两个库：

```
pip install pandas matplotlib
```

10.1 先分析一份销售数据

本节任务：一份各城市各月的销售记录，算出总额、按城市汇总、找出最好的月份，再把结果画成柱状图。

```
1 import pandas as pd
2
3 df = pd.DataFrame({
4     "city": ["杭州", "杭州", "北京", "北京", "广州", "广州"],
5     "month": [1, 2, 1, 2, 1, 2],
6     "sales": [120, 150, 200, 180, 90, 130],
7 })
8
9 print(df)
10 print("\n总销售额: ", df["sales"].sum())
11 print("平均每单: ", df["sales"].mean())
12
13 print("\n按城市汇总: ")
14 print(df.groupby("city")["sales"].sum())
15
16 print("\n卖得最好的一条: ")
17 print(df.loc[df["sales"].idxmax()])
```

运行结果：

```
city month sales
0 杭州 1 120
1 杭州 2 150
2 北京 1 200
3 北京 2 180
4 广州 1 90
5 广州 2 130
```

```
总销售额: 870
平均每单: 145.0

按城市汇总:
city
北京 380
广州 220
杭州 270
Name: sales, dtype: int64

卖得最好的一条:
city 北京
month 1
sales 200
Name: 2, dtype: object
```

和上一章比,最大的不同是**每列都有名字**,取数据时写 `df["sales"]` 而不是记住它是 ★核心第几列。分组汇总也只要一行。下面把常用操作过一遍。

10.2 DataFrame, 带列名的表

本节任务: 会建表、看表、取列取行。

DataFrame 就是一张二维表,每列有名字、有自己的类型。可以从字典建,也可以从文件读:

```
1 import pandas as pd
2
3 df = pd.DataFrame({"name": ["小明", "小红"], "score": [86, 95]})
4
5 df2 = pd.read_csv("scores.csv") # 从上一章存的 CSV 读
6 df.to_csv("out.csv", index=False, encoding="utf-8-sig") # 存回文件
```

读进来先看几眼,这是拿到数据的第一步:

```
1 print(df.head()) # 前五行
2 print(df.shape) # 几行几列
3 print(df.columns) # 有哪些列
4 print(df.dtypes) # 每列是什么类型
5 print(df.describe()) # 数值列的统计摘要,个数 平均 最大最小等
```

```
6 print(df.info()) # 每列有多少非空值，查缺失很有用
```

取列用方括号加列名，取多列传一个列表：

```
1 print(df["score"]) # 一列
2 print(df[["name", "score"]]) # 多列，注意是两层方括号
```

取行有两种写法要分清。loc 按标签取，iloc 按位置取：

★核心

```
1 print(df.loc[0]) # 标签为 0 的那一行
2 print(df.iloc[0]) # 第 0 行
3 print(df.loc[0, "name"]) # 标签 0 行的 name 列
4 print(df.iloc[0:2]) # 前两行
```

刚建的表标签就是 0 1 2，两者看着一样。等筛选过后标签会保留原来的编号，这时两者就不同了。

10.3 筛选和新增列

本节任务：按条件挑出想要的行，并算出新的列。

筛选写法和上一章的数组几乎一样：

```
1 df = pd.DataFrame({"name": ["小明", "小红", "小刚"],
2                      "chinese": [86, 95, 55],
3                      "math": [92, 88, 61]})
4
5 print(df[df["chinese"] >= 60]) # 语文及格的
6 print(df[(df["chinese"] >= 60) & (df["math"] >= 90)]) # 两个条件都满足
```

同样要用 & 和竖线，每个条件加括号。

新增一列直接赋值就行：

```
1 df["total"] = df["chinese"] + df["math"]
2 df["average"] = df[["chinese", "math"]].mean(axis=1)
3 print(df)
```

按某列排序：

```
1 print(df.sort_values("total", ascending=False)) # 总分从高到低
```

10.4 分组汇总

本节任务：按某一列把数据分成几组，each 组各算各的。

这是表格工具最有价值的功能。`groupby` 按某列的取值把行分组，再对每组做统计：

```
1 df = pd.DataFrame({
2     "city": ["杭州", "杭州", "北京", "北京"],
3     "sales": [120, 150, 200, 180],
4 })
5
6 print(df.groupby("city")["sales"].sum()) # 每个城市的总额
7 print(df.groupby("city")["sales"].mean()) # 每个城市的平均
8 print(df.groupby("city").size()) # 每个城市几条记录
9 print(df.groupby("city")["sales"].agg(["sum", "mean", "max"])) # 一次算多个
```

读法是先按 city 分组，再从每组里取 sales 列，再对它求和。理解了这三步，各种变体都能自己写出来。

10.5 处理缺失值

本节任务：真实数据总有空缺，学会查出来并处理掉。

读进来的数据常有空格子，pandas 里显示成 NaN。先查有多少：

```
1 import numpy as np
2 df = pd.DataFrame({"name": ["小明", "小红", "小刚"],
3                     "score": [86, np.nan, 55]})
4
5 print(df.isna().sum()) # 每列有几个缺失
```

处理办法有两类，**丢掉或者填上**：

★ 核心

```
1 print(df.dropna()) # 丢掉有缺失的行
2 print(df.fillna(0)) # 填成 0
3 print(df.fillna(df["score"].mean())) # 填成这一列的平均值
```

选哪种要看情况。数据量大、缺失少，丢掉最省事。缺失多或者每行都珍贵，就得填，填平均值是常见做法。不要不管它，带着 NaN 做计算，结果多半也是 NaN。

10.6 把结果画出来

本节任务：用几行代码把统计结果画成图并存成文件。

pandas 自带画图，底层用的是 matplotlib：

```
1 import matplotlib
2 matplotlib.use("Agg") # 不弹窗，直接存文件
3 import matplotlib.pyplot as plt
4
5 by_city = df.groupby("city")["sales"].sum()
6 by_city.plot(kind="bar") # 柱状图
7 plt.title("Sales by City")
8 plt.tight_layout()
9 plt.savefig("sales.png", dpi=120)
10 print("图已存成 sales.png")
```

kind 换成别的就是别的图，line 折线、barh 横向柱状、hist 直方图、scatter 散点。

有两个实用提醒。第一，在脚本里画图要先设成 Agg 模式，否则某些环境会卡在弹窗上。第二，matplotlib 默认不带中文字体，图里的中文会变成方块，所以上面标题用了英文。要显示中文得指定一个系统里有的中文字体：

```
1 plt.rcParams["font.sans-serif"] = ["SimHei"] # Windows 上的黑体
2 plt.rcParams["axes.unicode_minus"] = False # 负号正常显示
```

10.7 小结

这一章处理了带列名的真实数据。DataFrame 是二维表，每列有名字，read_csv 读、to_csv 存。拿到数据先用 head shape columns dtypes describe info 看几眼。取列用方括号加列名，取行 loc 按标签、iloc 按位置。筛选和数组一样用条件，组合条件要加括号并用 & 和竖线。新增列直接赋值。groupby 分组汇总是最有价值的功能，读法是先分组、再取列、再统计。缺失值先用 isna 查，再决定 dropna 丢掉还是 fillna 填上。画图用 plot 加 kind，脚本里记得设 Agg 模式，中文要另设字体。下一章把这些串成一个完整项目。

本章知识点

- DataFrame —— 带列名的二维表，pandas 的核心结构
- read_csv 与 to_csv —— 从文件读表和把表存成文件
- head 与 info —— 拿到数据先看几行、看每列类型和缺失情况
- describe —— 一次给出数值列的个数、平均、最大最小等摘要
- 取列 —— 方括号加列名，取多列要用两层方括号

- **loc 与 iloc** —— loc 按标签取, iloc 按位置取, 筛选过后两者会不同
- **条件筛选** —— 和数组一样, 组合条件用 & 和竖线并各自加括号
- **新增列** —— 直接给一个新列名赋值即可
- **groupby** —— 按某列分组再对每组统计, 先分组再取列再统计
- **缺失值** —— 显示成 NaN, 用 isna 查, dropna 丢掉或 fillna 填上
- **plot** —— 画图, kind 决定图形种类, 脚本里要先设 Agg 模式
- **中文字体** —— matplotlib 默认不带中文, 要指定字体否则显示成方块